

Presentación proyecto dataxperience

Análisis sobre el estudio nacional
de caracterización sociolingüística
de la población sorda colombiana





Agenda



Introducción

De acuerdo con la OMS las personas con problemas de audición del mundo suman alrededor del 5% de la población mundial. En Colombia, para 2024, el 1.1% de la población tiene algún tipo de problema de audición, siendo Bogotá y Antioquia las zonas de mas influencia.





DESCRIPCIÓN DE LAS
CARACTERÍSTICAS
DE POBLACIÓN
SORDA EN
COLOMBIA

Objetivos principales

Justificación del proyecto



Tras una búsqueda en la página de datos abiertos de Colombia, llegamos al estudio Nacional de Caracterización Sociolingüística de la Población Sorda Colombiana realizado en 2024, nos pareció relevante dado aprender, y trabajar con lenguajes de programación y las personas sorda es muy relevante en el mundo globalizado y crear espacios en este ámbito para las personas sordas o de baja audición baja las barreras de comunicación, lo que crea una sociedad mas inclusiva

Pregunta principal del proyecto

¿Existe relación entre el nivel de pérdida auditiva, el sexo y el desempeño comunicativo auto percibido en Lengua de Señas Colombiana, español oral y español escrito de la población sorda colombiana encuestada en el Estudio Nacional de Caracterización Sociolingüística?



Preguntas orientadoras



- ¿Que habilidad de comunicación domina mejor esta población?
- ¿La habilidad varia dependiendo la discapacidad de la persona?
- ¿las habilidades de comunicación varían entre hombres y mujeres?





DESCRIPCIÓN DE LAS
CARACTERÍSTICAS
DE POBLACIÓN
SORDA EN
COLOMBIA

Proceso de limpieza de datos

Proceso limpieza de datos

Descarga inicial

Primero se descargó el dataset de datos.gov.co en formato CSV; luego, en un cuaderno de Colab, se importaron las librerías y finalmente se visualizó la información general del archivo en bruto. El dataset contiene la respuesta de 102 preguntas a 1,000 personas encuestadas.

```
 import re # busca patrones en texto (saca el 2 de "2. Medio")
import numpy as np # calculo con numeros; np.nan = "sin dato"
import pandas as pd # trabaja con tablas de datos (como Excel)

df = pd.read_csv(CARPETA / "dataset_raw.csv", encoding="utf-8")
filas_orig, columnas_orig = df.shape # (filas, columnas)
nulos_orig = int(df.isnull().sum().sum()) # celdas vacias en total
filas_duplicadas = int(df.duplicated().sum())
ids_duplicados = int(df["usuarios_id"].duplicated().sum())

print(f"Personas encuestadas (filas): {filas_orig}")
print(f"Preguntas (columnas): {columnas_orig}")
print(f"Celdas vacias en total: {nulos_orig}")
print(f"Filas duplicadas: {filas_duplicadas}")
```

```
Personas encuestadas (filas): 1000
Preguntas (columnas): 102
Celdas vacias en total: 30,037
Filas duplicadas: 0
```

Proceso limpieza de datos

Identificación de las columnas relevantes

Al revisar la información del data set, se evidencia que todas las columnas vienen con object como tipo de dato, esto debido a que las respuestas son alfanuméricas y no de tipo numero. Por lo anterior, es necesario identificar las columnas relevantes para resolver la pregunta problema y a estas realizarle la limpieza correspondiente



```
cols_texto = df.select_dtypes(exclude="number").columns.tolist()
print(f"Columnas de texto: {len(cols_texto)} de {columnas_orig}")
print(df["_38_c_mo_califica_su_desempe"].head(3).tolist())
```

```
Columnas de texto: 101 de 102
['1. Alto', '1. Alto', '2. Medio']
```

Proceso limpieza de datos

Identificación de las columnas relevantes

Se revisan las columnas del data set y se identifican que las columnas relevantes para resolver la pregunta problema son la pregunta, por lo que se realiza la limpieza de estas columnas 12. Sexo, 15. ¿Que nivel de perdida auditiva tiene?, 38. ¿Cómo califica su desempeño comunicativo en LSC?, 39. ¿Cómo califica su desempeño comunicativo en español oral? Y 40. ¿Cómo califica su desempeño comunicativo en español escrito?. Por lo anterior, se empieza la limpieza con la columna de la pregunta 12.

```
▶ sexo = datos["sexo"].apply(primer_opcion)
print(sexo.value_counts())
print(f"Sexo sin dato: {int((sexo == 'No reportado').sum())} de {len(datos)}")
```

```
sexo
2. Masculino      491
1. Femenino       463
3. Prefiero no decir    29
No reportado      17
Name: count, dtype: int64
Sexo sin dato: 17 de 1000
```

En la pregunta 12 (Sexo), 17 de las 1.000 respuestas (1,7 %) no tienen dato. Se marcan como 'No reportado' y quedan fuera del cálculo; no se eliminan filas del dataset. Las otras categorías son: masculino, femenino y prefiero no decir.

Proceso limpieza de datos

Limpieza de datos

Se analizan cada una de las preguntas y se realiza la limpieza correspondiente:

En la pregunta 15 la respuesta NaN es la más frecuente (356 de 1.000, el 35,6 %): ¿no está diagnosticado? ¿quien respondió no conocía el diagnóstico? Como tiene menos del 40 % de nulos, se marca 'No reportado' y se excluye del cálculo, sin imputar datos. Otras 16 personas respondieron 'No sabe' y también se excluyen. Quedan 628 respuestas válidas."

```
perdida = datos["nivel_perdida_auditiva"].apply(primer_opcion)
print(perdida.value_counts())
print(f"Sin dato (No reportado): {int((perdida == 'No reportado').sum())}")
print(f"'No sabe': {int(perdida.str.contains('No sabe').sum())}")
print(f"Respuestas validas: {int(datos['nivel_perdida_auditiva_num'].notna().sum())}")
```

```
nivel_perdida_auditiva
No reportado          356
4. Hipoacusia Profunda  311
2. Hipoacusia Moderada  144
3. Hipoacusia Severa    127
1. Hipoacusia Leve       46
5. No sabe             16
Name: count, dtype: int64
Sin dato (No reportado): 356
'No sabe':             16
Respuestas validas:    628
```

Proceso limpieza de datos

```
def quitar_repetidos(valor):  
    if not isinstance(valor, str) or "," not in valor:  
        return valor  
    partes = [p.strip() for p in valor.split(",")]  
    vistas = []  
    for p in partes:  
        if p not in vistas:  
            vistas.append(p)  
    return ", ".join(vistas)  
  
celdas_corregidas = 0  
for col in cols_texto:  
    nueva = df[col].apply(quitar_repetidos)  
    celdas_corregidas += int(((nueva != df[col]) & df[col].notna()).sum()) # solo celdas con dato que cambiaron  
    df[col] = nueva  
print(f"2.2 Celdas con opciones repetidas corregidas: {celdas_corregidas}")
```

2.2 Celdas con opciones repetidas corregidas: 921

```
def primera_opcion(valor):  
    if not isinstance(valor, str):  
        return valor  
    return valor.split(",")[0].strip()  
  
multiples = {c: int(datos[c].apply(lambda v: isinstance(v, str) and "," in v).sum())  
              for c in ORDINALES + NOMINALES + ["estrato"]}  
print("3.2 Filas con mas de una opcion marcada (se toma la primera):")  
for c, n in multiples.items():  
    if n:  
        print(f"      {c:28s} {n}")
```

3.2 Filas con mas de una opcion marcada (se toma la primera):

nivel_educativo	15
edad_adquisicion_lsc	8
edad_adquisicion_oral	9
edad_adquisicion_escrito	5
desempeno_lsc	5
desempeno_oral	9
desempeno_escrito	10
frecuencia_uso_1	4
frecuencia_uso_2	10
frecuencia_uso_3	6
frecuencia_uso_4	5
grupo_poblacional	126
estrato	6

En las preguntas 38, 39 y 40 hay respuestas con 2 o más opciones marcadas (entre 5 y 10 filas por pregunta). Si la misma opción se repite, se reduce a una sola (dedupe_cell). Si son opciones distintas, para el análisis se toma la primera opción marcada (first_choice) y el script cuenta cuántas filas están afectadas.

Resumen del dataset depurado

```
▶ pct_nulos = df.isnull().mean() * 100
cols_no_aplica = [c for c in pct_nulos[pct_nulos > 40].index if c != "usuarios_id"]
cols_no_reportado = pct_nulos[(pct_nulos > 0) & (pct_nulos <= 40)].index.tolist()
cols_sin_nulos = int((pct_nulos == 0).sum())

for col in cols_no_aplica:
    df[col] = df[col].fillna("No aplica")
for col in cols_no_reportado:
    df[col] = df[col].fillna("No reportado")

print(f"2.4 Columnas 'No aplica' (>40 % vacias):      {len(cols_no_aplica)}")
print(f"    Columnas 'No reportado' (0-40 % vacias): {len(cols_no_reportado)}")
print(f"    Columnas sin ningun vacio:                {cols_sin_nulos}")
print(f"    Nulos restantes en el dataset:              {int(df.isnull().sum().sum())}")

df.to_csv(SALIDA / "dataset_clean.csv", index=False, encoding="utf-8") # index=False: sin numeracion extra
print(f"Dataset limpio: {df.shape[0]} filas x {df.shape[1]} columnas")
```

```
2.4 Columnas 'No aplica' (>40 % vacias):      27
    Columnas 'No reportado' (0-40 % vacias): 73
    Columnas sin ningun vacio:                2
    Nulos restantes en el dataset:            0
Dataset limpio: 1000 filas x 102 columnas
```

Una vez depurado el dataset tenemos 1,000 respuesta y 102 columnas, sin valores nulos y se centra en las 4 preguntas clave para responder la pregunta problema de este proyecto.



DESCRIPCIÓN DE LAS
CARACTERÍSTICAS
DE POBLACIÓN
SORDA EN
COLOMBIA

Análisis estadístico

Metodología estadística aplicada

1

Variables ordinales

se codifican como números (1=alto, 2=medio, 3=bajo, 4=nulo) para poder calcular media, mediana, moda, varianza y desviación estándar.

2

Variables nominales

Sexo no tiene orden natural: solo se calcula moda y distribución de frecuencias.

3

Detección de outliers

Método de rango intercuartílico (IQR). En escalas cortas, un outlier es una categoría poco común, no un error de digitación.

4

Correlación de Pearson

Se calcula 'r' entre pares clave de variables para medir la fuerza de la relación entre ellas.

Medidas de tendencia central

Variable	N	Media	Mediana	Moda
Sexo	983	N/A	N/A	2. Masculino
Desempeño en LSC (lenguaje de señas colombiano)	944	1.84	2. Medio	2. Medio
Desempeño oral	942	2.79	3. Bajo	4. Nulo
Desempeño escrito	942	2.28	2. Medio	2. Medio
Nivel de pérdida auditiva	628	3.12	3. Severa	4. Hipoacusia Profunda

Lectura rápida:

Las tres medidas de tendencia establecen en que el desempeño en LSC es la habilidad con mejor evaluada ubicándose entre medio y alto


Medidas de tendencia central

Variable	N	Varianza	Desviación estándar	Rango
Sexo	983	N/A	N/A	N/A
Desempeño en LSC (lenguaje de señas colombiano)	944	0.68	0.82	3.0
Desempeño oral	942	1.12	1.06	3.0
Desempeño escrito	942	0.79	0.89	3.0
Nivel de pérdida auditiva	628	1.0	1.0	3.0

Lectura rápida:

Nuevamente el desempeño en LSC es el mas homogéneo, lo que quiere decir que esta es la habilidad mas usada para comunicarse a nivel general.


Resultados de la encuesta por pregunta




La relación entre femenino y masculino es bastante equilibrada, lo que nos sugiere que la pérdida de audición se presenta prácticamente de manera equitativa entre estos dos sexos.

Resultados de la encuesta por pregunta

En esta pregunta pasa algo muy particular y es que las mayoría personas que respondieron la encuesta, no conocían el diagnóstico, esto se explica debido a que en varios casos quienes respondieron la encuesta son acudientes, familiares o incluso los mismos entrevistadores, por lo que para caracterizar mejor a esta población, se establece que la hipoacusia profunda es el nivel mas frecuente entre esta población.




Resultados de la encuesta por pregunta




Los resultados de esta pregunta nos permiten observar como la población sorda tiene un alto nivel de habilidad en el manejo de lengua de señas, por lo que se puede inducir que es su manera de comunicarse con el mundo exterior

Resultados de la encuesta por pregunta

A diferencia de la pregunta anterior, aquí se puede ver como las personas sordas no tienen un buen desarrollo de habilidades comunicativas en español oral, esto se explica debido a que se aprende a hablar escuchando e imitando los sonidos y gesticulaciones del exterior, ellos al tener limitaciones, es muy difícil lograr tener un desarrollo optimo en esta habilidad.




Resultados de la encuesta por pregunta



A diferencia de la habilidad oral, en el caso de la habilidad escrita, si se tiene un mayor desarrollo de esta, teniendo un 46,8% de las respuestas validas tiene nivel medio; o 44,1% si se calcula sobre las 1000 filas. Por anterior, se puede deducir que para mejorar la comunicación e inclusión con esta población, se deben priorizar canales de lenguaje de señas y canales escritos.


Comparativa de variables: Sexo




En esta grafica se identifica como hay una distribución consistente en cuanto al nivel de perdida entre los hombres y las mujeres. En ambos casos el nivel de perdida dominante es el de hipoacusia profunda. Esto sugiere que el sexo no es un factor determinante en la severidad de la pérdida auditiva dentro de la muestra, es decir, la condición auditiva parece distribuirse de forma similar independientemente del sexo, por lo anterior, los programas de inclusión no deberían tener diferenciación frente a este factor

Comparativa de variables: LSC

En esta comparativa las personas con hipoacusia profunda presentan el mayor porcentaje de desempeño "Alto" en LSC (49%), superando incluso a quienes tienen hipoacusia leve (31.8%). Esto sugiere que, a mayor severidad de la pérdida auditiva, existe mayor dependencia y por tanto mayor dominio de la Lengua de Señas Colombiana como canal principal de comunicación




Comparativa de variables: español oral



A diferencia de LSC, a mayor severidad de la pérdida auditiva, peor es el desempeño en español oral, esto tiene relación con lo mencionado anteriormente, el habla se enseña escuchando y repitiendo, por lo que al existir fallas en el habla, esta habilidad no se desarrolla de manera natural, sino que debe ser trabajada de manera alternativa, por lo que entre mas profundo sea el nivel de perdida, mas difícil va a ser lograr un buen desempeño en el habla

Comparativa de variables: español escrito

En esta habilidad no hay una relación tan marcada como en las dos anteriores, por lo que esta habilidad se comporta como un punto intermedio entre LSC y español oral: no depende directamente del oído como el oral, pero tampoco se beneficia de la misma forma que la LSC con la pérdida auditiva severa



Conclusiones

- La lengua de señas Colombiana es la habilidad mejor evaluada y la mas homogénea, es el canal principal de comunicación
- El español oral es la más debil y empeora con la perdida auditiva
- El español escrito es un punto intermedio, sirve como un plan de respaldo
- El sexo no marca la diferencia, las soluciones se diseñan por nivel de perdida
- La edad de adquisicion del lenguaje pesa

Aplicaciones en la vida diaria

Una persona sorda con hipoacusia profunda pide una cita médica: hoy el primer canal suele ser una llamada telefónica, justo donde su desempeño es peor.

Lengua de señas

Video-intérprete por videollamada, desde el celular o una pantalla en el punto de atención.

Canal Escrito

Cita por chat o WhatsApp, pantallas para escribir y textos en lenguaje simple.

Contacto Temprano

Tamizaje auditivo pediátrico y cursos de LSC para las familias.



Gracias

Michel Alejandro Maldonado Torres
Samuel David Serrato Silva
María Paz Sandoval

